

GOAI 世界人工智能开源大赛 · Agent Infra

OJGuard | 在线测评事故响应与可信重评

AgentTeams

驱动调查、处置与验证；确定性工具守住事实和执行边界

单人团队 · 可运行开源作品

核心不是“会分析”，而是让 AgentTeams 驱动可信处置

● 高风险场景

批量误判影响成绩与晋级

必须精确定界并可回溯

● 协同控制面

1 Manager + 6 Worker

职责、上下文和权限分离

● 动态决策

多候选实验按证据补选

INCONCLUSIVE 不强行推进

● 受控执行

技术 / 业务 / 关闭三道门禁

灰度失败立即暂停与重规划

● 能力底座

9 Skills × 12 MCP 工具

任务抽象与系统接入分层

● 工程证据

66 tests + 三类事故场景

真实协作与确定性恢复分级

一次环境回归，可能改写数百人的成绩与晋级

错误率 8.3% → 41.4%，影响 703 名候选人、742 条提交和 72 个晋级结果；OJGuard 将异常转为可复核根因、冻结范围、受控批次和关闭证据。

一次运行时回归，污染的不只是判题

固定种子 20260802 · Java 运行时回归实验

参赛规模

5,000

20,000 次提交

影响范围

703 / 742

候选人 / 受影响提交

成绩变化

703

预计晋级变化 72

可信核验

100%

量/漏/越界均为 0



核心价值

- 把主观排查变成可复核证据链
- 只重评受影响提交，并保证幂等
- 关闭前强制校验覆盖率与边界

同一闭环，覆盖多类 OJ 事故

已实现三类可执行固定种子场景

Java 运行时回归

703 / 742 受影响

正常 3/3 OK

退化 3/3 TLE

镜像对照 + SHA-256 证据

主演示场景

评测节点退化

118 / 119 受影响

性能偏差与节点关联

预计晋级变化 14

节点隔离 + 增量重评

退化场景 A

Checker 缺陷

71 / 73 受影响

判定逻辑与版本关联

预计晋级变化 8

规则修复 + 结果核验

退化场景 B

TRIAGING → INVESTIGATING → IMPACT_ASSESSING → REMEDIATION_PLANNING
APPROVAL_PENDING → EXECUTING → REJUDGING → VERIFYING → RESOLVED

固定种子 20260802 · Java Runner：正常 3/3 OK，退化 3/3 TLE

同一 AgentTeams 闭环覆盖三类 OJ 故障

运行时回归 703 人 / 742 条 / 72 个晋级变化; 节点退化 118 人 / 119 条 / 14 个变化; Checker 缺陷 71 人 / 73 条 / 8 个变化。三类场景均完成 100% 覆盖核验。

一次运行时回归，污染的不只是判题

固定种子 20260802 · Java 运行时对账实验

参赛规模

5,000

20,000 次提交

影响范围

703 / 742

候选人 / 受影响提交

成绩变化

703

预计晋级变化 72

可信核验

100%

量/漏/越界均为 0



核心价值

- 把主观排查变成可复核证据链
- 只重评受影响提交，并保证幂等
- 关闭前强制校验覆盖率与边界

同一闭环，覆盖多类 OJ 事故

已实现三类可执行固定种子场景

Java 运行时回归

703 / 742 受影响

正常 3/3 OK

退化 3/3 TLE

镜像对照 + SHA-256 证据

主演示场景

评测节点退化

118 / 119 受影响

性能偏差与节点关联

预计晋级变化 14

节点隔离 + 增量重评

泛化场景 A

Checker 缺陷

71 / 73 受影响

判定逻辑与版本关联

预计晋级变化 8

规则修复 + 结果核验

泛化场景 B

TRIAGING → INVESTIGATING → IMPACT_ASSESSING → REMEDIATION_PLANNING
APPROVAL_PENDING → EXECUTING → REJUDGING → VERIFYING → RESOLVED

复用状态机、证据契约和重评引擎; 新增场景只扩展 Playbook 与 Adapter

AgentTeams 决策，状态机约束执行

Incident Manager 读取 IncidentContext 并选择 RouteOption; Worker 调用 Skill / MCP。主链: TRIAGING → INVESTIGATING → IMPACT_ASSESSING → REMEDIATION_PLANNING → APPROVAL_PENDING → EXECUTING → REJUDGING → VERIFYING → RESOLVED; 异常进入 PAUSED 或 HUMAN_REVIEW_REQUIRED。

证据驱动的在线测评事故闭环

Agent 负责协同与解释，确定性工具负责事实与执行



治理底座

十阶段事故状态机 · 审批留痕 · 高风险动作阻断 · 重评幂等键 · 覆盖率与边界核验

SQLite 事故台账 · JSON / HTML 报告 · Java 真实运行对照 · AgentTeams 运行证据

1 Manager + 6 Worker: 职责制衡

Manager 决定“下一步调用谁”；Signal、Root Cause、Impact、Planner、Executor、Verifier 分别交付可校验产物。IncidentContext、Evidence ID、范围哈希和 AgentRun/Event 在角色间传递，避免一个 Agent 同时提出结论、执行写操作并自我验收。

主管理器编排 6 个专职 Worker

共享事故编号与事实快照，输出可追溯阶段结果

Team Leader

汇总状态 / 分派任务

Signal Worker

信号融合

Root Cause

根源证据

Impact Worker

影响定界

Plan Worker

重评计划

Rejudge Worker

批次执行

Verify Worker

关闭核验

自主分析，受控执行

建议可并行，高风险动作必须通过人工闸门

并行研判

根源 / 影响 / 重评计划

证据冲突

置信度不足则回溯调查

批准执行

单人按角色上下文确认

三道安全闸门

1

控制组：确认修复不会改变健康提交

3

全量重评：等待执行，批次状态可恢复

2

灰度批次：比较错误率、耗时与成绩漂移

关闭条件：覆盖 100%，重/漏/越界均为 0

下一步由 AgentTeams 决定，失败由确定性策略接管

● 合法路由

状态生成 RouteOption 集合

Manager 只能在合法动作中选择

● 竞争假设

多条可证伪根因并行存在

选择信息增益更高的实验

● 证据不足

INCONCLUSIVE 保持调查态

从剩余候选补选而非硬判

● 灰度失败

PAUSED 并阻断全量批次

保存失败证据并执行回滚

● 恢复计划

revision 2 supersedes rev1

撤销旧审批，重新灰度验证

● 人工门禁

技术 / 业务 / 关闭审批

Agent 无批准接口，不能自批

Skill 与工具集成 • 9 Skills × 12 MCP

Skill 定义可复用任务，MCP 连接确定性事实与受控动作

● 信号分诊

normalize / correlate Skills

信号、提交与部署读取工具

● 根因实验

hypothesis / replay Skills

候选假设与对照重放工具

● 题包审计

package-audit Skill

Checker、数据与配置审计

● 影响定界

impact-scope Skill

候选人 / 提交集合 + SHA-256

● 计划审批

remediation-plan Skill

版本计划与审批状态查询

● 执行核验

execute / verify / report Skills

幂等批次、独立核验与报告

上下文、可观测性与安全边界

每次决策、工具调用和状态推进都有可查询依据

● 共享上下文

IncidentContext 保存业务状态

范围、计划、审批和 Evidence ID

● 协同轨迹

AgentRun / Event 顺序留痕

路由、Worker、工具和理由可查

● 实时观测

快照 API + 增量事件 + SSE

支持恢复、审计和前端消费

● 异常处理

超时、重试、冲突和转人工

失败不会被静默吞掉

● 安全控制

读写分级 + 幂等 + 范围哈希

批量动作受审批和状态约束

● RAG 扩展

保留知识检索适配器契约

可接 Runbook, 不虚构已实现能力

可行性、落地与开放计划

已有可运行闭环；66 项测试、Ruff、Vue build 与提交包审计通过

● 前端工作台

Vue 3：总览、详情与审批

只展示用户需要的业务入口

● 服务与台账

FastAPI + SQLite 状态机

事故、路由、批次与事件 API

● Agent Infra

AgentTeams + Skills + MCP

核心协同链已真实运行验收

● 旁路接入

先读告警、日志和提交数据

只生成建议，不写正式成绩

● 受控写入

控制组 → 灰度 → 分批全量

阈值、回滚和三道人工门禁

● 开放复用

Apache-2.0 + OJ Adapter

开放代码、契约、场景与证据

DeepSeek 与 6 个 Worker 从 TRIAGING 动态推进到 RESOLVED

● 非事后复核

live_dynamic_routing

posthoc_review = false

● 完整团队

1 Leader + 6 Worker

六个专业角色均留下独立响应

● 动态决策

11 次 ROUTE_DECISION

每轮重读状态并核对预期结果

● 有界调用

20 条模型响应

11 路由 + 8 Worker + 1 报告

● 人工门禁

技术 / 业务 / 关闭共 3 次

单人以不同角色上下文验收

● 独立核验

覆盖 100%，重复 / 遗漏 / 越界 = 0

最终状态 RESOLVED

关键结论均可从仓库文件定位，并用对应脚本重复验证

● AgentTeams 核心

11 路由 · 8 Worker · 20 响应

*agentteams-demo-result.json ·
export_agentteams_evidence.ps1*

● 异常恢复

INCONCLUSIVE 补选 · PAUSED → rev2

*deterministic-recovery-evidence.json ·
generate_orchestration_recovery_evidence.py*

● 三类场景

703/742 · 118/119 · 71/73; 均 100%

scenario-summary.json · generate_incident_evidence.py

● Java 对照

正常 3/3 OK · 退化 3/3 TLE

*java-runtime-comparison.json ·
run_java_regression_experiment.py*

● 质量门禁

66 tests · Ruff · Vue build

python -m unittest discover -s tests -v

● 提交包

必需文件 / UTF-8 名称 / 链接 / 秘密扫描

*build_submission_package.ps1 ·
verify_submission_package.py*