

OJGuard

多智能体编程题包发布门禁

Agent 提出风险假设，确定性程序验证假设；每个严重结论都可重放、可审计。



传统题包检查能发现格式错误，却难以覆盖跨文件语义缺陷

现有工具擅长

- 目录与格式检查
- 编译和已有测试
- 单文件静态规则

仍依赖人工经验

- 题面与 Validator 冲突
- 标准程序边界与溢出
- 漏测错误算法
- Checker 被恶意输出绕过

可信结论来自证据闭环，而不是模型自信



原则

无确定性证据的结论只能保留为 suspected 或转人工复核。

五个 Agent 以专业边界相互制衡

JUDGE MANAGER

拆解任务、协调冲突、执行发布规则；不代替人类审批。

规格审计

题面、样例、配置和校验器

程序分析

算法、数值范围、复杂度风险

对抗测试

边界、差分、错误解驱动测试

Checker 审计

EOF、Token、数值与错误退出

推理与执行分离，所有路径汇入同一个审计状态



七个 Skill 与八个 MCP 工具形成可复用能力层

01 · 题包检查

结构、角色、路径安全

02 · 规格提取

来源保留、冲突显式化

03 · 标程审计

风险假设与验证计划

04 · 对抗生成

预算、合法性、固定种子

05 · 差分测试

Oracle、候选、反例

06 · Checker 审计

真实绕过执行

07 · 发布门禁

纯规则、不可越权

08 · 证据重放

SHA-256 与运行复核

主演示用真实 Docker 执行复现四类缺陷

整数溢出

3000000000
vs 2147000000

CONFIRMED

规格冲突

合法边界被
Validator 拒绝

CONFIRMED

测试遗漏

负数反例淘汰
错误正数求和


CONFIRMED

Checker 绕过

正确答案后追加
垃圾 Token 仍通过


CONFIRMED

每条严重 Finding 都能追溯到完整证据链



运行产物：4 Finding · 4 Evidence · JSONL Trace · JSON/HTML 报告

补丁永远先进入副本，并经过两次人工确认



已验证

完整流程通过，原始题包树哈希保持不变；系统未连接真实 OJ 发布。

十题确定性基准命中全部标注缺陷，且没有误阻断干净题包

100%

Precision
8 TP / 0 FP

100%

Recall
8 个标注缺陷

0%

Clean false block
2 个干净对照

0

LLM calls
确定性基线无费用

报告边界

scope = deterministic_baseline_only。该数字验证规则引擎回归稳定性，不冒充 AgentTeams 或大模型效果。

Vue 3 控制台把证据、审批与原始轨迹放在同一条工作线上

总览

运行与门禁状态

题包上传

安全 ZIP 导入

运行详情

Finding / Evidence / Trace

审批中心

Diff 与双确认

基准评测

指标和逐题结果

架构

Agent / Skill / MCP

系统设置

预算、端口、健康

响应式

桌面与移动端

安全边界、模型费用与 RAG 状态都明确可见

沙箱

默认断网、非 root、资源与输出受限
； Agent 不接触 Docker API。

模型预算

DeepSeek deepseek-chat; 6 元提醒、8 元停非必要调用、保留 2 元演示。

RAG

8010 端口和 API 契约已预留；初赛默认关闭，并明确显示为禁用状态。

AgentTeams 真实协作与工程闭环均已完成，提交材料进入收口

已有证据

- K8s 后端 · 无宿主 Socket
- 5 个 OJGuard 角色真实协作
- Matrix 分派 · MCP 工具调用
- 4 Finding · 4 Evidence · 哈希复验
- 双审批、回归与 Vue 正式构建

仍需参赛者完成

- 确认主体与成员信息
- 审阅作品简介和创新点
- 录制真人审批与回归视频
- 确认平台字段和截止时间
- GitHub 推送与最终上传

真实轨迹: OJGUARD-DEMO-002 · RUN-DEMO-1E470FB440 · OJGUARD_DEMO_COMPLETE

技术闭环已完成，下一步只做终审、录屏与提交

01

安全方案 B

已完成：K8s 后端，不暴露
Docker Socket

02

真实协作

已完成：4/4 Worker 回复
与 Leader 汇总

03

费用控制

已完成：保守估算上限约 1.
70 元

04

提交收口

待参赛者：终审、录屏、打
包与上传

目标：让评审能从每个结论回到原始协作消息、确定性执行记录与可重放证据。