

GOAI 世界人工智能开源大赛 · Agent Infra

OJGuard | 在线测评事故响应与可信重评

多 Agent 协同调查、受控处置与可验证关闭

单人团队 · 可运行开源作品

从异常信号到可信重评的 Agent Infra

● 应用场景

在线测评批量误判事故

招聘考试、教育与竞赛 OJ

● 核心目标

定位根因并冻结影响范围

只重评真正受影响的提交

● 方案设计

状态机驱动多 Agent 协作

任务、证据和权限相互约束

● 能力分工

1 个 Manager + 6 个 Worker

独立调查、规划、执行与核验

● 工具底座

9 Skills / 12 MCP 工具

确定性事实与动作全部留痕

● 落地基础

前后端、Runner 与审计台账

63 项测试和三类场景证据

第一章

场景与价值

一次环境回归会污染成绩与晋级结果

固定场景数据中错误率从 8.3% 升至 41.4%，影响 703 名候选人与 742 次提交；处理结果必须能够被复核和追责。

一次运行时回归，污染的不只是判题

固定种子 20260802 · Java 运行时对题实验

参赛规模

5,000

20,000 次提交

影响范围

703 / 742

候选人 / 受影响提交

成绩变化

703

预计晋级变化 72

可信核验

100%

量/漏/越界均为 0



核心价值

- 把主观排查变成可复核证据链
- 只重评受影响提交，并保证幂等
- 关闭前强制校验覆盖率与边界

同一闭环，覆盖多类 OJ 事故

已实现三类可执行固定种子场景

Java 运行时回归

703 / 742 受影响

正常 3/3 OK

退化 3/3 TLE

镜像对照 + SHA-256 证据

主演示场景

评测节点退化

118 / 119 受影响

性能偏差与节点关联

预计晋级变化 14

节点隔离 + 增量重评

退化场景 A

Checker 缺陷

71 / 73 受影响

判定逻辑与版本关联

预计晋级变化 8

规则修复 + 结果核验

退化场景 B

统一状态机: DETECTED → DIAGNOSING → SCOPED → APPROVED → REJUDGING → VERIFYING → RESOLVED

固定种子 20260802 · Java Runner 真实
OK / TLE 对照

事故响应需要同时保护公平、效率与信任

● 招聘考试

批量误判可能改变录用排序

需要精确范围与晋级重算

● 在线教育

错误成绩影响学习反馈

需要快速纠错与解释证据

● 竞赛 OJ

环境波动可能改变排名

需要统一规则和可信重评

● 运营效率

缩短定位、审批和重评时间

减少人工交叉核对成本

● 用户信任

每个结论均可回溯证据

投诉处理不依赖口头解释

● 审计合规

关键动作经过门禁并留痕

支持事后复盘和责任界定

同一闭环覆盖三类 OJ 事故

运行时回归、节点退化和 Checker
缺陷共享状态机与证据契约，新增事故类型只需扩展 Playbook
和工具适配器。

一次运行时回归，污染的不只是判题

固定种子 20260802 · Java 运行时回归实验

参赛规模

5,000

20,000 次提交

影响范围

703 / 742

候选人 / 受影响提交

成绩变化

703

预计晋级变化 72

可信核验

100%

量/漏/越界均为 0



核心价值

- 把主观排查变成可复核证据链
- 只重评受影响提交，并保证幂等
- 关闭前强制校验覆盖率与边界

同一闭环，覆盖多类 OJ 事故

已实现三类可执行固定种子场景

Java 运行时回归

703 / 742 受影响

正常 3/3 OK

退化 3/3 TLE

镜像对照 + SHA-256 证据

主演示场景

评测节点退化

118 / 119 受影响

性能偏差与节点关联

预计晋级变化 14

节点隔离 + 增量重评

泛化场景 A

Checker 缺陷

71 / 73 受影响

判定逻辑与版本关联

预计晋级变化 8

规则修复 + 结果核验

泛化场景 B

统一状态机: DETECTED → DIAGNOSING → SCOPED → APPROVED → REJUDGING → VERIFYING → RESOLVED

三类固定种子场景覆盖率均为 100%

第二章

方案设计

对应评分维度

多 Agent 协同与自主闭环能力

25%

Agent 负责决策，确定性工具负责事实与执行

信号进入 IncidentContext; Manager 选择合法 RouteOption; Worker 调用 Skill/MCP; 状态机校验审批、批次和验证结果。

证据驱动的在线测评事故闭环

Agent 负责协同与解释，确定性工具负责事实与执行



治理底座

十阶段事故状态机 · 审批留痕 · 高风险动作阻断 · 重评幂等键 · 覆盖率与边界核验

SQLite 事故台账 · JSON / HTML 报告 · Java 真实运行对照 · AgentTeams 运行证据

1 个 Manager 编排 6 个专职 Worker

Signal 聚合信号, Root Cause 设计实验, Impact 冻结范围, Planner 生成计划, Executor 受控执行, Verifier 独立核验。



主任务被拆为六个可验收阶段

● 信号归一

聚合告警、日志和投诉

Signal Worker 输出统一快照

● 根因调查

建立竞争假设与实验候选

Root Cause 输出证据结论

● 影响定界

计算候选人和提交集合

Impact 输出冻结范围哈希

● 处置规划

生成控制、灰度和全量计划

Planner 输出版本化方案

● 受控执行

仅运行已获批批次

Executor 使用幂等键写入结果

● 独立核验

重算覆盖、重复和边界

Verifier 决定能否关闭事故

结构化 IncidentContext 代替隐式聊天记忆

● 状态快照

保存事故阶段与当前约束

每次路由读取同一事实源

● 历史事件

AgentRun/Event 顺序记录

支持恢复、增量查询和 SSE

● 证据引用

假设、实验、范围和批次有 ID

Worker 输出必须携带 refs

● 结构化输出

Agent 结果成为下一步输入

Schema 校验字段和状态

● 工具回写

MCP 结果写入事故台账

避免只存在模型对话中

● 交接校验

状态机验证预期结果

不完整上下文不会推进流程

动态路由受状态机与证据共同约束

● 合法选项

当前状态生成 RouteOption

拒绝跨阶段或越权动作

● 候选实验

同一根因可有多个实验

Manager 选择信息量更高者

● 证据不足

INCONCLUSIVE 保持调查态

允许从剩余候选中补选

● 确定性校验

工具结果决定状态是否推进

模型不能替代数值判断

● 状态转移

每一步声明 expected state

异常结果进入明确分支

● 人工门禁

高风险路由等待审批

批准对象与计划版本绑定

关闭事故前必须通过六类独立检查

● 实验充分性

根因实验必须 PASSED

INCONCLUSIVE 不视为成功

● 范围一致性

重评集合匹配冻结哈希

禁止跨范围成绩写入

● 批次完整性

控制、灰度、全量均完成

失败或暂停批次不计覆盖

● 幂等一致性

重复重评数量必须为 0

批次键阻止重复执行

● 结果重算

重新计算成绩与晋级变化

不复用执行 Agent 的结论

● 关闭条件

覆盖 100%，漏评与越界为 0

全部断言通过才 RESOLVED

失败不会被隐藏，而是进入可恢复状态

● 证据不足

实验返回 INCONCLUSIVE

保持调查态并补选实验

● 工具失败

超时、Schema 或依赖异常

记录错误并转人工处理

● 状态冲突

Worker 输出不符合预期

拒绝写入并保留上下文

● 灰度失败

事故立即进入 PAUSED

回滚失败批次并阻断全量

● 审批拒绝

计划保持不可执行

修改计划后重新发起审批

● 恢复失败

canary_retry 未通过

继续暂停或升级人工处置

风险控制贯穿建议、审批、执行与关闭

● 最小权限

Worker 只能调用授权工具

分析角色没有批量执行权

● 双重审批

技术与业务门禁分别留痕

高风险动作必须显式批准

● 范围冻结

计划绑定影响集合哈希

后续批次禁止扩大范围

● 幂等保护

事故、批次和提交都有键

重试不会产生重复写入

● 暂停回滚

灰度异常立即阻断全量

失败批次保存替代关系

● 秘密隔离

密钥仅从本地环境读取

日志、证据与提交包均脱敏

对应评分维度

Skill 工程体系与生态复用

25%

第三章

Skill 与工具集成

9 个 Skill 覆盖调查、处置与核验

每个 Skill

定义输入输出、调用条件、依赖工具、失败处理、安全边界、幂等键、验收标准、复用价值和协作关系。

9 个 Skill，把经验沉淀为可复用能力

统一输入输出、依赖、失败处理与审批边界

信号与定界

信号归一

事件关联

影响定界

根因审查

控制复现

题包审计

处置执行

处置规划

受控重评

独立核验

一致性核验

事故报告

12 个 MCP 工具：信号 / 部署 / 重放 / 题包 / 影响 / 重评 / 成绩 / 核验 / 报告

12 个工具提供确定性事实与受控动作

● 信号与部署

读取异常分布和变更记录

为事故分诊提供事实

● 假设与重放

生成候选并执行对照实验

返回 PASSED / INCONCLUSIVE

● 题包审计

检查 Checker、数据与配置

定位题目侧系统性缺陷

● 影响定界

计算候选人和提交集合

冻结范围并生成 SHA-256

● 计划与审批

创建版本化重评计划

审批结果绑定计划 revision

● 执行与验证

运行批次并生成报告

幂等执行与独立一致性核验

Skill 抽象任务，MCP 连接真实系统

● 结构契约

工具声明参数与返回 Schema

Agent 输出可被稳定校验

● 调用审计

记录工具、参数和结果摘要

失败重试保留完整事件链

● 错误处理

超时、重试和转人工明确

不会静默吞掉工具异常

● 权限边界

读操作与写操作分级授权

批量动作受审批和状态约束

● 上下文回写

工具结果进入 IncidentContext

后续 Agent 共享同一事实

● RAG 扩展

保留知识检索适配器契约

可接 Runbook 与历史事故库

对应评分维度

工程落地与安全可审计

20%

第四章

可行性与落地计划

核心闭环已有可运行实现和验证依据

● 业务前端

Vue 3 事故工作台

总览、详情、审批与重评

● 服务后端

FastAPI + 领域状态机

事故、路由、事件和报告 API

● 数据台账

SQLite 可审计存储

保存状态、审批、批次与事件

● Agent Infra

AgentTeams + Skills + MCP

角色、任务和工具契约完整

● 执行验证

Java Runner + 固定种子

真实 OK/TLE 与三类场景报告

● 质量保证

63 tests + Ruff + Vue build

秘密扫描与提交包审计通过

从旁路观察逐步进入生产写路径

● 阶段一

接入告警、日志与提交数据

建立只读适配器和基线指标

● 阶段二

旁路生成事故与影响建议

人工确认结果，不写入成绩

● 阶段三

启用审批和控制组重评

验证权限、幂等和回滚能力

● 阶段四

开放灰度与分批执行

达到阈值后再进入全量

● 阶段五

接入监控、工单和 Runbook

沉淀事故模板和经验规则

● 验收指标

范围准确、覆盖完整、零越界

同时评估耗时、成本与可靠性

以可复用契约降低其他 OJ 的接入成本

● 开源许可

Apache-2.0

允许使用、修改和再分发

● 开放代码

前后端、Runner 与状态机

提供本地运行和容器配置

● 开放能力

9 Skills / 12 MCP 工具

输入输出和安全边界完整

● 扩展接口

OJ Adapter / RAG / Playbook

新增系统无需改写核心流程

● 复现资产

三类场景、测试与证据报告

便于验证迁移后的行为一致性

● 演进方向

补充队列、配置与资源事故

持续完善适配器和观测标准