

GOAI 世界人工智能开源大赛 · Agent Infra

OJGuard

在线测评事故响应与可信重评

从异常信号到可信重评，以证据驱动闭环

单人团队 · 可运行开源作品

作品简介

● 项目名称

面向在线测评运营

OJGuard

● 问题与场景

环境异常会污染评测结果

难定位、难定界、难安全重评

● 核心解决方案

多 Agent 协同 + 确定性工具

发现→定界→审批→重评→核验

● 创新点与差异化

证据优先、幂等重评、状态机治理

高风险动作必须人工批准

● 开放 / 复用价值

9 Skills / 12 MCP 工具

可迁移节点退化与 Checker 缺陷

● 当前进展

后端、Vue3 前端、AgentTeams
动态路由与恢复

63 项测试 + 两类协作证据可复核

目录

1 场景与价值

2 方案总览

3 AgentTeams 协同

4 Skill / MCP 工程

5 工程落地与证据

6 开源与复用

7 演示路径

8 验证结果

对应评分维度

场景价值与行业可复制性

25%

第一章

场景与价值

真实事故：Java 运行时回归

镜像切换后错误率从 8.3% 升至 41.4%。OJGuard
将异常还原为可复核证据、精确影响范围与可信重评任务。

一次运行时回归，污染的不只是判题

固定种子 20260802 · Java 运行时回归实验

参赛规模

5,000

20,000 次提交

影响范围

703 / 742

候选人 / 受影响提交

成绩变化


703

预计晋级变化 72

可信核验

100%

量/漏/越界均为 0



核心价值

- 把主观排查变成可复核证据链
- 只重评受影响提交，并保证幂等
- 关闭前强制校验覆盖率与边界

同一闭环，覆盖多类 OJ 事故

已实现三类可执行固定种子场景

Java 运行时回归

703 / 742 受影响

正常 3/3 OK

退化 3/3 TLE

镜像对照 + SHA-256 证据

主演示场景

评测节点退化

118 / 119 受影响

性能偏差与节点关联

预计晋级变化 14

节点隔离 + 增量重评

退化场景 A

Checker 缺陷

71 / 73 受影响

判定逻辑与版本关联

预计晋级变化 8

规则修复 + 结果核验

退化场景 B

统一状态机: DETECTED → DIAGNOSING → SCOPED → APPROVED → REJUDGING → VERIFYING → RESOLVED

固定种子 20260802 ·
三类场景均可复现

第二章

方案总览

方案总览

共享 IncidentContext 生成合法 RouteOption; Manager 选择实验, AgentRun/Event 按序记录路由、工具、门禁与状态。

证据驱动的在线测评事故闭环

Agent 负责协同与解释, 确定性工具负责事实与执行



治理底座

十阶段事故状态机 · 审批留痕 · 高风险动作阻断 · 重评幂等键 · 覆盖率与边界核验

SQLite 事故台账 · JSON / HTML 报告 · Java 真实运行对照 · AgentTeams 运行证据

对应评分维度

多 Agent 协同与自主闭环能力

25%

第三章

AgentTeams 协同设计

AgentTeams 协同设计

3 个实验候选可补选；灰度失败进入 PAUSED，经新计划与重新审批恢复；真实协作已完成 20 条响应。

主管理器编排 6 个专职 Worker

共享事故编号与事实快照，输出可追溯阶段结果

Team Leader

汇总状态 / 分派任务

Signal Worker

信号融合

Root Cause

根因证据

Impact Worker

影响边界

Plan Worker

重评计划

Rejudge Worker

批次执行

Verify Worker

关闭核验

自主分析，受控执行

建议可并行，高风险动作必须通过人工闸门

并行研判

根因 / 影响 / 重评计划

证据冲突

置信度不足则回溯调查

批准执行

单人按角色上下文确认

三道安全闸门

1

控制组：确认修复不会改变健康提交

3

全量重评：等待执行，批次状态可恢复

2

灰度批次：比较错误率、耗时与成绩漂移

关闭条件：覆盖 100%，重/漏/越界均为 0

对应评分维度

Skill 工程体系与生态复用

25%

第四章

Skill / MCP 工程体系

9 个可复用 Skill

9 个 Skill 定义协作边界；12 个 MCP

工具支持候选实验与版本化恢复，确定性状态机拒绝合同外路由和越权执行。



对应评分维度

工程落地与安全可审计


20%

第五章

工程落地与运行证据

可复现证据链

真实 AgentTeams 证明 6 个 Worker 参与；零成本证据验证 3 候选补选与灰度恢复；两类证据分级、不混淆。



对应评分维度

开放 / 开源贡献

5%

第六章

开放 / 开源贡献

开放 / 开源贡献

● 代码仓库

完整源码与运行说明

github.com/AzusaFish/OJGuard

● 可复用资产

9 Skills、12 MCP 工具、三类场景

可单独接入其他 OJ

● 扩展边界

适配器契约预留

队列 / 配置类事故可新增 Playbook

● 运行方式

PowerShell 脚本或本地启动

演示数据一键生成

● 证据包

Runner、AgentRun、动态路由与恢复

真实协作 + 零成本异常链证据

● 完成状态

前后端与闭环已可运行


Demo 由参赛者现场录制

第七章・对应「当前进展」与整体可行性

Demo 与提交状态

已完成的闭环证据

真实协作从 TRIAGING 推进至 RESOLVED；确定性证据补齐“3 候选→补选实验”和“灰度失败→新计划→重审批→恢复灰度”，63 项测试全部通过。



从事故创建到可信关闭：全链路已跑通

AgentTeams

6 / 6

Worker 页面协作

影响范围

703 / 742

候选人 / 提交

批次


4 / 4

控制 / 灰度 / 全量

最终状态

RESOLVED

覆盖率 100%



GitHub: github.com/AzusaFish/OJGuard

Apache-2.0 · Vue3 · FastAPI · AgentTeams · 证据与三类场景库提供